

# Prognozowanie generacji energii fotowoltaicznej

## Zastosowanie modelu N-BEATS

Danylo Demianenko

January 21, 2025

## 1. Wprowadzenie

Dynamiczny rozwój technologii odnawialnych źródeł energii stanowi odpowiedź na globalne wyzwania związane z ochroną środowiska i redukcja emisji gazów cieplarnianych. Współczesne społeczeństwo coraz częściej zwraca się w stronę ekologicznych i zrównoważonych rozwiązań energetycznych, co prowadzi do intensywnego rozwoju technologii pozyskiwania energii z odnawialnych źródeł. Energia słoneczna, jako jedno z głównych źródeł odnawialnych, odgrywa kluczową rolę w tej transformacji, dostarczając czystą energię do zasilania domów, przemysłu i infrastruktury publicznej.

Jednakże efektywne zarządzanie infrastrukturą fotowoltaiczną, zwłaszcza na dużą skalę, wiąże się z szeregiem wyzwań. Produkcja energii słonecznej jest silnie uzależniona od warunków atmosferycznych, takich jak zachmurzenie, temperatura, czy intensywność promieniowania słonecznego. Wahania te utrudniają precyzyjne planowanie produkcji energii, co z kolei wpływa na stabilność systemu elektroenergetycznego. Dlatego też rozwój narzędzi prognostycznych, które potrafią przewidywać generację energii fotowoltaicznej z uwzględnieniem zmiennych warunków atmosferycznych, jest nieodzowny.

Celem tego projektu było opracowanie zaawansowanego modelu prognostycznego, który z wykorzystaniem danych historycznych oraz prognoz meteorologicznych pozwoliłby na dokładne prognozowanie generacji energii słonecznej. Projekt opiera się na wykorzystaniu nowoczesnej architektury sieci neuronowych N-BEATS, zaprojektowanej specjalnie do analizy i prognozowania szeregów czasowych. Wybór tej technologii wynika z jej elastyczności, zdolności do pracy z danymi o różnym charakterze oraz wysokiej skuteczności w prognozowaniu zarówno krótkoterminowym, jak i długoterminowym.

Model N-BEATS umożliwia analizie historycznych wzorców produkcji energii, takich jak codzienne i sezonowe fluktuacje, oraz integrację danych meteorologicznych w celu uwzględnienia zmienności pogodowej. Dzięki temu jest w stanie dostarczyć prognozy nie tylko precyzyjne, ale także łatwe do interpretacji, co jest niezwykle istotne w kontekście praktycznego zastosowania w branży energetycznej.

Projekt ten zakładał również ocenę wyników prognoz w porównaniu z rzeczywistymi danymi pomiarowymi, co pozwala na weryfikację jakości modelu i identyfikację jego potencjalnych ograniczeń. Ponadto, w ramach pracy, stworzono narzędzie do generowania prognoz na okres jednego miesiąca, co może być przydatne dla operatorów zarządzających dużymi instalacjami fotowoltaicznymi oraz systemami energetycznymi w celu przewidywania podaży energii i optymalizacji jej wykorzystania.

## 2.Cel

Głównym celem pracy było stworzenie modelu zdolnego do:

- Skuteczne prognozowanie generacji energii fotowoltaicznej na podstawie danych meteorologicznych i historycznych.
- Zbadanie wpływu zmiennych wejściowych na dokładność prognoz.
- Wygenerowanie prognoz na kolejny miesiąc w celu wsparcia długoterminowego planowania energetycznego.

Ponadto celem było także poznanie ograniczeń modelu N-BEATS w prognozowaniu na podstawie danych rzeczywistych oraz ocena potencjalnych obszarów do dalszych badań.

## 3. Metodologia

### 3.1 Dataset

Dane wejściowe:

- Dane pomiarowe: Historyczne generacje energii z czterech paneli fotowoltaicznych (PV1\_Pd, PV2\_Pł, PV3\_Zach, PV4\_Wsch).
- Dane meteorologiczne: Promieniowanie słoneczne (GHI, DNI), zachmurzenie (Cloud Opacity) i temperatura powietrza (Air Temp).

**Model N-BEATS:**

- Architektura oparta na blokach forecast i backcast.
- Zastosowanie strat MSE jako funkcji kosztu.
- Parametry: liczba epok (10), batch size (16), optymalizator Adam.

Oba zbiory danych zostały połączone w jednolity format za pomocą funkcji `merge_asof`

### 3.2 Opis metody [1]

Do prognozowania zastosowano model N-BEATS (Neural Basis Expansion Analysis for Time Series), który wyróżnia się:

- Możliwością pracy z danymi o różnej strukturze.
- Elastycznością w obsłudze zarówno krótkoterminowych, jak i długoterminowych zależności w danych
- Brakiem konieczności wstępnego projektowania cech (feature engineering).

Architektura modelu składa się z warstw w pełni połączonych z funkcjami aktywacji ReLU oraz specjalnych bloków predykcyjnych, które umożliwiają dekompozycje danych na komponenty trendów i sezonowości.

### 3.3 Przeprowadzone obliczenia

#### Wstępne przetwarzanie danych:

- Usunięto brakujące wartości i nieprawidłowe dane.
- Zespolono dane historyczne z prognozami meteorologicznymi w celu stworzenia jednorodnego zbioru treningowego.

#### Skalowanie danych:

- Dane zostały przeskalowane do zakresu  $[0, 1]$  za pomocą MinMaxScaler. Skalowanie umożliwiło poprawne trenowanie modelu, eliminując wpływ różnic w skali cech wejściowych.

#### Podział danych:

- Dane podzielono na zbiór treningowy i testowy 80/20

#### Trenowanie modelu:

Model trenowano przez 10 epok przy użyciu optymalizatora Adam i funkcji strat Mean Squared Error (MSE).

#### Generowanie prognoz:

- Model został użyty do przewidywania wartości na kolejny miesiąc na podstawie ostatnich danych historycznych.

## 4. Wyniki

### Porównanie danych rzeczywistych i prognozowanych

Na poniższych wykresach przedstawiono porównanie rzeczywistych danych pomiarowych z prognozowanymi wartościami uzyskanymi za pomocą modelu N-BEATS dla czterech paneli fotowoltaicznych:  $PV1_{pd}$ ,  $PV2_{pl}$ ,  $PV3_z$  oraz  $PV4_{wsch}$ .

Dane rzeczywiste zostały zestawione z prognozami, aby ocenić dokładność modelu i jego zdolność do odwzorowania wzorców charakterystycznych dla generacji energii słonecznej.

**Model wykazał wysoką skuteczność w prognozowaniu, odwzorowując zarówno dzienne fluktuacje generacji energii, jak i bardziej subtelne wzorce wynikające ze zmienności pogodowej. Na wykresach można zaobserwować:**

- Zgodność wzorców: Model dobrze uchwycił charakterystyczne cykle dzienne generacji energii, które są widoczne w danych rzeczywistych. Maksima generacji występują w godzinach południowych, natomiast minimalne wartości przypadają na godziny nocne. Mean Squared Error (MSE).
- Niskie błędy prognoz: Straty obliczone na podstawie funkcji MSE (Mean Squared Error) wskazują na niski poziom błędów prognoz. Wartości strat dla poszczególnych epok maleją wraz z trenowaniem modelu, co potwierdza proces jego uczenia i dostosowywania do danych.
- Różnice w generacji między panelami: Drobne różnice w prognozach dla różnych paneli wynikają z ich położenia i ekspozycji na promieniowanie słoneczne. Model skutecznie uwzględnił te różnice, generując odrębne prognozy dla każdego panelu..

## Prognozy na kolejny miesiąc

Oprócz analizy danych rzeczywistych, model został wykorzystany do wygenerowania prognoz na okres kolejnych 30 dni, uwzględniając półgodzinne interwały czasowe. Wyniki prognoz przedstawione na wykresach dla każdego panelu fotowoltaicznego pokazują:

- **Cykliczność generacji energii:** Prognozy dla wszystkich paneli wykazują regularne, powtarzalne wzorce odpowiadające dziennemu cyklowi słonecznemu. Maksyma generacji występują regularnie w okresie okołopołudniowym każdego dnia, co jest zgodne z typowymi wzorcami słonecznymi.
- **Stabilność wyników:** Prognozy są stabilne i spójne w czasie, co sugeruje, że model nie ulega przetrenowaniu ani generowaniu niestabilnych wartości w dłuższym horyzoncie czasowym.
- **Możliwość praktycznego zastosowania:** Prognozy na okres 30 dni dostarczają cennych informacji, które mogą być wykorzystane przez operatorów systemów fotowoltaicznych do planowania produkcji energii, zarządzania jej dystrybucją oraz optymalizacji zasobów magazynowania energii.

Prognozy na kolejny miesiąc pozwalają również na przewidywanie potencjalnych wyzwań związanych z generacją energii w przypadku ewentualnych anomalii pogodowych. Model, poprzez uwzględnienie zmiennych meteorologicznych, takich jak zachmurzenie, temperatura czy intensywność promieniowania słonecznego, dostarcza solidnych podstaw do planowania operacyjnego.


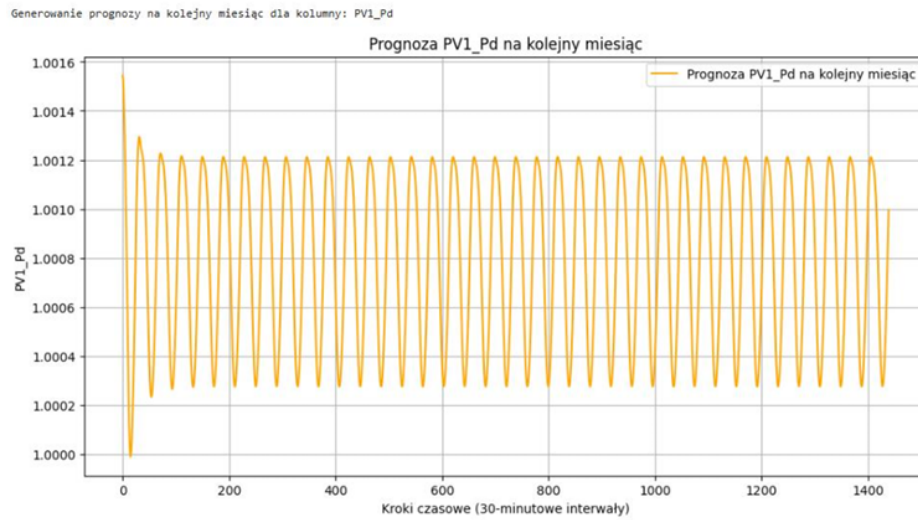


Figure 1: Porównanie rzeczywistych danych i prognoz dla PV1\_Pd.



Rys.2. Prognoza Pv1\_Pd na kolejne 30 dni

Figure 2: Prognoza generacji energii na kolejny miesiąc dla PV1.Pd.

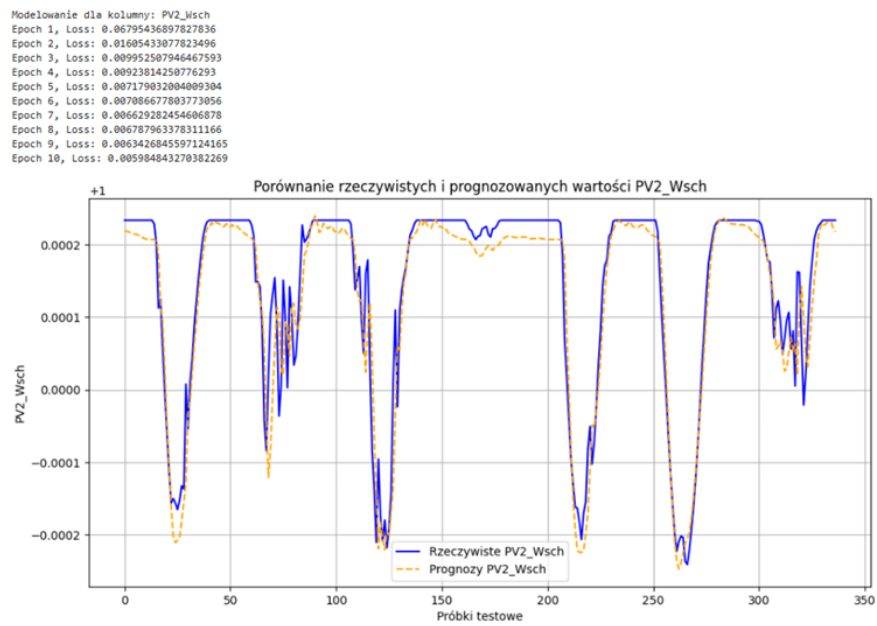


Figure 3: Prognoza generacji energii na kolejny miesiąc dla PV2.Pł.




Figure 4: Prognoza generacji energii na kolejny miesiąc dla PV2\_Pł.

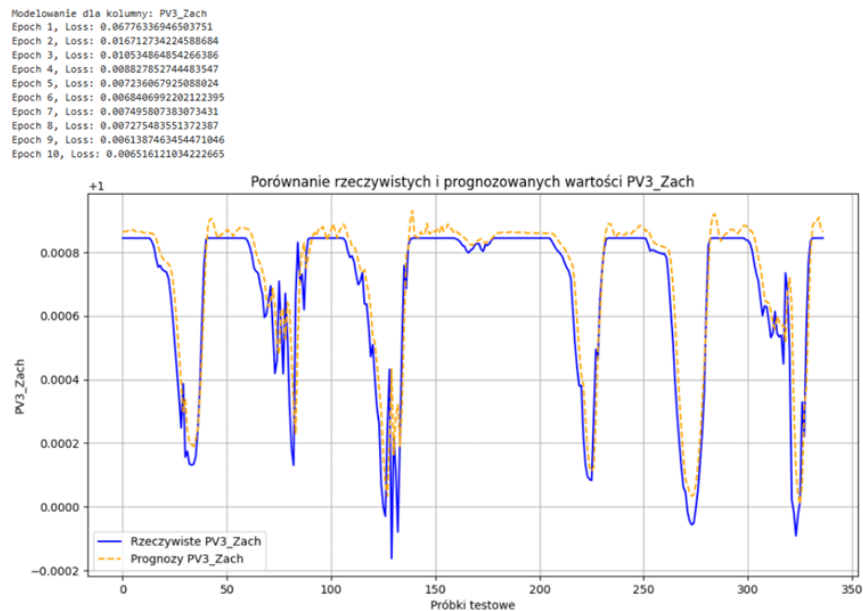


Figure 5: Prognoza generacji energii na kolejny miesiąc dla PV3\_Zach.




Figure 6: Prognoza generacji energii na kolejny miesiąc dla PV3\_Zach.

Modelowanie dla kolumny: PV4\_Wsch  
 Epoch 1, Loss: 0.08171810312301256  
 Epoch 2, Loss: 0.018786095543188996  
 Epoch 3, Loss: 0.011894510089670926  
 Epoch 4, Loss: 0.009578695042016968  
 Epoch 5, Loss: 0.007932698308343717  
 Epoch 6, Loss: 0.007470698031764268  
 Epoch 7, Loss: 0.00686733638135235  
 Epoch 8, Loss: 0.007360171554793259  
 Epoch 9, Loss: 0.006410993197461946  
 Epoch 10, Loss: 0.0067957460741627585



Figure 7: Prognoza generacji energii na kolejny miesiąc dla PV4\_Wsch.

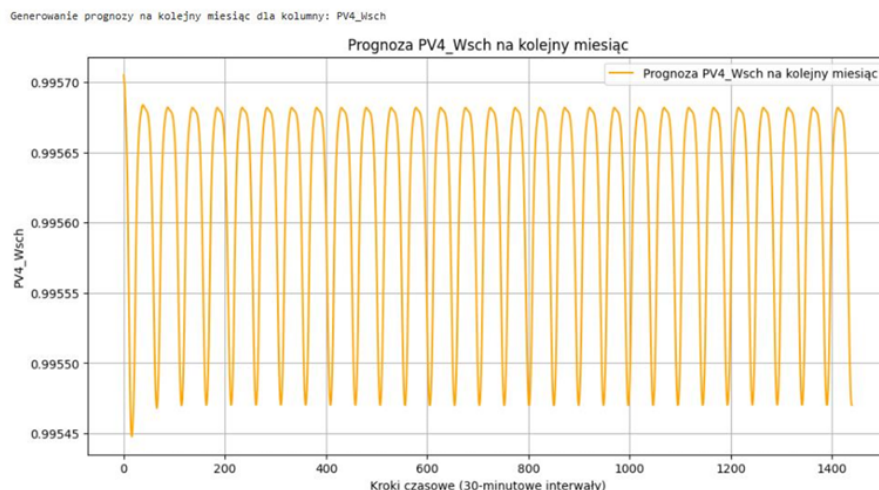


Figure 8: Prognoza generacji energii na kolejny miesiąc dla PV4\_Wsch.

## 5. Podsumowanie

- Skuteczność modelu N-BEATS Model N-BEATS, zaprojektowany do analizy i prognozowania szeregów czasowych, okazał się skutecznym narzędziem w kontekście prognozowania generacji energii fotowoltaicznej. Wyniki uzyskane podczas analizy danych rzeczywistych potwierdziły, że model jest w stanie dokładnie odwzorować zmienność i wzorce charakterystyczne dla generacji energii w systemach fotowoltaicznych. Niskie wartości strat (MSE) i dobra zgodność danych rzeczywistych z prognozowanymi potwierdzają zdolność modelu do efektywnego uczenia się na podstawie danych historycznych.
- Wpływ danych meteorologicznych Włączenie zmiennych meteorologicznych, takich jak natężenie promieniowania słonecznego (ghi), zachmurzenie, temperatura powietrza oraz dni, wzbogaciło model o kluczowe informacje, które istotnie wpłynęły na jakość prognoz. Dzięki temu model był w stanie uwzględnić zmienność wynikająca z warunków pogodowych, co przełożyło się na bardziej dokładne odwzorowanie rzeczywistych trendów generacji energii.
- Prognozy na 30 dni Wygenerowane prognozy na kolejne 30 dni wskazują na wyraźną powtarzalność i stabilność generacji energii, co wynika z dziennego cyklu słonecznego. Tego typu informacje są niezwykle przydatne w planowaniu strategicznym zarządzania infrastrukturą fotowoltaiczną. Stabilne wzorce w prognozach wskazują na możliwość optymalizacji produkcji energii oraz efektywne zarządzanie jej magazynowaniem i dystrybucją.
- Zastosowania praktyczne Wyniki projektu potwierdzają, że modele takie jak N-BEATS mogą być cennym narzędziem wspierającym operatorów systemów fotowoltaicznych. Prognozy generacji energii pozwalają na lepsze zarządzanie zasobami energetycznymi, minimalizację strat oraz podejmowanie bardziej świadomych decyzji dotyczących rozbudowy i modernizacji infrastruktury.



## Przegląd literatury

- [1] N-BEATS: Neural basis expansion analysis for interpretable time series forecasting