

## Contents

<b>hscolor1</b>	<b>Wprowadzenie</b>	<b>2</b>
<b>hscolor2</b>	<b>Cel</b>	<b>2</b>
<b>hscolor3</b>	<b>Metodologia</b>	<b>2</b>
hscolor3.1	Dataset . . . . .	2
hscolor3.2	Opis metody . . . . .	2
hscolor3.3	Przeprowadzone obliczenia . . . . .	2
hscolor3.4	Wykorzystane metryki oceny . . . . .	2
<b>hscolor4</b>	<b>Wyniki</b>	<b>3</b>
hscolor4.1	Porównanie danych rzeczywistych i prognozowanych . . .	3
hscolor4.2	Prognozy na kolejny miesiąc . . . . .	3
<b>hscolor5</b>	<b>Podsumowanie</b>	<b>3</b>
<b>hscolor6</b>	<b>Przegląd literatury</b>	<b>3</b>
=0pt		

# Prognozowanie generacji energii fotowoltaicznej

## Zastosowanie modelu N-BEATS

Danylo Demianenko<sup>a</sup>

<sup>a</sup>Politechnika Opolska, Opole, Polska

### ARTICLE INFO

#### Keywords:

N-BEATS  
fotowoltaika  
prognozowanie  
energia odnawialna  
szeregi czasowe

### ABSTRACT

Projekt dotyczy zastosowania zaawansowanego modelu N-BEATS w prognozowaniu generacji energii fotowoltaicznej. Model pozwala analizować dane historyczne oraz meteorologiczne w celu przewidywania generacji energii, uwzględniając zmienne pogodowe i wzorce czasowe. Wyniki wskazują na wysoką skuteczność modelu w odwzorowywaniu rzeczywistych danych oraz jego potencjał w planowaniu energetycznym.

## 1. Wprowadzenie

Dynamiczny rozwój technologii odnawialnych źródeł energii stanowi odpowiedź na globalne wyzwania związane z ochroną środowiska i redukcją emisji gazów cieplarnianych. Energia słoneczna, jako jedno z głównych źródeł odnawialnych, odgrywa kluczową rolę w tej transformacji, dostarczając czystą energię do zasilania domów, przemysłu i infrastruktury publicznej.

Celem tego projektu było opracowanie modelu prognostycznego, który z wykorzystaniem danych historycznych oraz prognoz meteorologicznych pozwoliłby na dokładne prognozowanie generacji energii słonecznej. Projekt opiera się na wykorzystaniu nowoczesnej architektury sieci neuronowych N-BEATS, zaprojektowanej specjalnie do analizy i prognozowania szeregów czasowych.

Model N-BEATS umożliwia analizę historycznych wzorców produkcji energii, takich jak codzienne i sezonowe fluktuacje, oraz integrację danych meteorologicznych w celu uwzględnienia zmienności pogodowej. Dzięki temu jest w stanie dostarczyć prognozy nie tylko precyzyjne, ale także łatwe do interpretacji, co jest niezwykle istotne w kontekście praktycznego zastosowania w branży energetycznej.

## 2. Cel

Głównym celem pracy było stworzenie modelu zdolnego do:

- Prognozowanie generacji energii fotowoltaicznej na podstawie danych meteorologicznych i historycznych.
- Zbadanie wpływu zmiennych wejściowych na jakość prognoz.
- Generowanie prognoz na kolejny miesiąc w celu wsparcia planowania energetycznego.

Ponadto celem było także poznanie ograniczeń modelu N-BEATS w prognozowaniu na podstawie danych rzeczywistych oraz ocena potencjalnych obszarów do dalszych badań.

ORCID(s):

## 3. Metodologia

### 3.1. Dataset

- Dane pomiarowe: Generacja energii z paneli fotowoltaicznych (PV1\_Pd, PV2\_Wsch, PV3\_Zach, PV4\_Wsch).
- Dane meteorologiczne: Promieniowanie słoneczne (GHI, DNI), zachmurzenie (Cloud Opacity), temperatura powietrza (Air Temp).

### 3.2. Opis metody

Do prognozowania zastosowano model N-BEATS (Neural Basis Expansion Analysis for Time Series), który wyróżnia się:

- Możliwością pracy z danymi o różnej strukturze.
- Elastycznością w obsłudze zarówno krótkoterminowych, jak i długoterminowych zależności w danych.

Architektura modelu składa się z bloków predykcyjnych i jest zoptymalizowana pod kątem analizy danych czasowych. Zastosowano funkcję strat Mean Squared Error (MSE) oraz optymalizator Adam.

### 3.3. Przeprowadzone obliczenia

- Usunięto brakujące dane i przekształcono zmienne wejściowe na jednorodny format.
- Przeskalowano dane za pomocą MinMaxScaler.
- Podzielono dane na zbiór treningowy i testowy (80/20).
- Model trenowano przez 10 epok przy użyciu optymalizatora Adam i funkcji strat Mean Squared Error (MSE)
- Model został użyty do przewidywania wartości na kolejny miesiąc na podstawie ostatnich danych historycznych.

### 3.4. Wykorzystane metryki oceny

- MSE (Mean Squared Error): mierzono średnią różnicę kwadratową pomiędzy rzeczywistymi a prognozowanymi wartościami.

## 4. Wyniki

### 4.1. Porównanie danych rzeczywistych i prognozowanych

Na poniższych wykresach przedstawiono porównanie rzeczywistych danych pomiarowych z prognozowanymi wartościami uzyskanymi za pomocą modelu N-BEATS dla czterech paneli fotowoltaicznych:

Dane rzeczywiste zostały zestawione z prognozami, aby ocenić dokładność modelu i jego zdolność do odwzorowania wzorców charakterystycznych dla generacji energii słonecznej.

Model wykazał wysoką skuteczność w prognozowaniu, odwzorowując zarówno codzienne fluktuacje generacji energii, jak i bardziej subtelne wzorce wynikające ze zmienności pogodowej. Na wykresach można zaobserwować:

- 1. Zgodność wzorców: Model dobrze uchwycił charakterystyczne cykle codzienne generacji energii, które są widoczne w danych rzeczywistych. Maksima generacji występują w godzinach południowych, natomiast minimalne wartości przypadają na godziny nocne.
- 2. Niskie błędy prognoz: Straty obliczone na podstawie funkcji MSE (Mean Squared Error) wskazują na niski poziom błędów prognoz. Wartości strat dla poszczególnych epok maleją wraz z treningiem modelu, co potwierdza proces jego uczenia i dostosowywania do danych.
- 3. Różnice w generacji między panelami: Drobne różnice w prognozach dla różnych paneli wynikają z ich położenia i ekspozycji na promieniowanie słoneczne. Model skutecznie uwzględnił te różnice, generując odrębne prognozy dla każdego panelu.

Ogólna jakość wyników wskazuje, że model N-BEATS jest odpowiedni do krótkoterminowego prognozowania generacji energii na podstawie danych historycznych i meteorologicznych.

### 4.2. Prognozy na kolejny miesiąc

Oprócz analizy danych rzeczywistych, model został wykorzystany do wygenerowania prognoz na okres kolejnych 10 dni, uwzględniając półgodzinne interwały czasowe. Wyniki prognoz przedstawione na wykresach dla każdego panelu fotowoltaicznego pokazują:

- 1. Cykliczność generacji energii: Prognozy dla wszystkich paneli wykazują regularne, powtarzalne wzorce odpowiadające codziennemu cyklowi słonecznemu. Maksima generacji występują regularnie w okresie okołopołudniowym każdego dnia, co jest zgodne z typowymi wzorcami słonecznymi.
- 2. Stabilność wyników: Prognozy są stabilne i spójne w czasie, co sugeruje, że model nie ulega przetrenowaniu ani generowaniu niestabilnych wartości w dłuższym horyzoncie czasowym.

- 3. Możliwość praktycznego zastosowania: Prognozy na okres 10 dni dostarczają cennych informacji, które mogą być wykorzystane przez operatorów systemów fotowoltaicznych do planowania produkcji energii, zarządzania jej dystrybucją oraz optymalizacji zasobów magazynowania energii.

## 5. Podsumowanie


- Skuteczność modelu N-BEATS Model N-BEATS, zaprojektowany do analizy i prognozowania szeregów czasowych, okazał się skutecznym narzędziem w kontekście prognozowania generacji energii fotowoltaicznej. Wyniki uzyskane podczas analizy danych rzeczywistych potwierdziły, że model jest w stanie dokładnie odwzorować zmienność i wzorce charakterystyczne dla generacji energii w systemach fotowoltaicznych. Niskie wartości strat (MSE) i dobra zgodność danych rzeczywistych z prognozowanymi potwierdzają zdolność modelu do efektywnego uczenia się na podstawie danych historycznych.
- Wpływ danych meteorologicznych Włączenie zmiennych meteorologicznych, takich jak natężenie promieniowania słonecznego (ghi), zachmurzenie, temperatura powietrza oraz dni, wzbogaciło model o kluczowe informacje, które istotnie wpłynęły na jakość prognoz. Dzięki temu model był w stanie uwzględnić zmienność wynikającą z warunków pogodowych, co przełożyło się na bardziej dokładne odwzorowanie rzeczywistych trendów generacji energii.
- Wygenerowane prognozy na kolejne 10 dni wskazują na wyraźną powtarzalność i stabilność generacji energii, co wynika z codziennego cyklu słonecznego. Tego typu informacje są niezwykle przydatne w planowaniu strategicznym zarządzania infrastrukturą fotowoltaiczną. Stabilne wzorce w prognozach wskazują na możliwość optymalizacji produkcji energii oraz efektywne zarządzanie jej magazynowaniem i dystrybucją.

## 6. Przegląd literatury

- [1] N-BEATS: Neural basis expansion analysis for interpretable time series forecasting

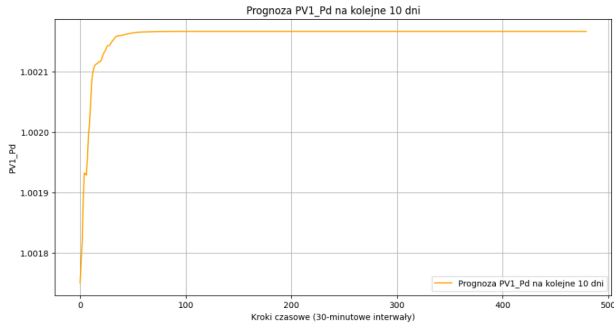
## References

Modelowanie dla kolumny: PV1\_Pd  
 Epoch 1, Loss: 0.0676173260749391  
 Epoch 2, Loss: 0.0205323775703833  
 Epoch 3, Loss: 0.013454442518893529  
 Epoch 4, Loss: 0.01128922281514628  
 Epoch 5, Loss: 0.00959889258478222  
 Epoch 6, Loss: 0.00959451595227139  
 Epoch 7, Loss: 0.0089543399994656  
 Epoch 8, Loss: 0.00897173519967124  
 Epoch 9, Loss: 0.00998783536395979  
 Epoch 10, Loss: 0.0301987793451823



**Figure 1:** Porównanie rzeczywistych i prognozowanych wartości dla PV1\_Pd.

Generowanie prognozy na kolejne 10 dni dla kolumny: PV1\_Pd




**Figure 2:** Prognoza generacji energii na kolejne 10 dni dla PV1\_Pd.

Modelowanie dla kolumny: PV2\_Wsch  
 Epoch 1, Loss: 0.0623973697882931  
 Epoch 2, Loss: 0.0145878092523214  
 Epoch 3, Loss: 0.009517546854337698  
 Epoch 4, Loss: 0.0085595594276131603  
 Epoch 5, Loss: 0.00809836794882899  
 Epoch 6, Loss: 0.008547163268341431  
 Epoch 7, Loss: 0.007123585230594531  
 Epoch 8, Loss: 0.005818688880497553  
 Epoch 9, Loss: 0.006827126234166831  
 Epoch 10, Loss: 0.005419813962216632



**Figure 3:** Porównanie rzeczywistych i prognozowanych wartości dla PV2\_Pf.

Generowanie prognozy na kolejne 10 dni dla kolumny: PV2\_Wsch




**Figure 4:** Prognoza generacji energii na kolejne 10 dni dla PV2\_Pf.

Modelowanie dla kolumny: PV3\_Zach  
 Epoch 1, Loss: 0.0754536389624386  
 Epoch 2, Loss: 0.0179417789921362  
 Epoch 3, Loss: 0.012427218478326664  
 Epoch 4, Loss: 0.009518898721385565  
 Epoch 5, Loss: 0.00846384627788232  
 Epoch 6, Loss: 0.008116731878626422  
 Epoch 7, Loss: 0.00732464736368561  
 Epoch 8, Loss: 0.006191379391964985  
 Epoch 9, Loss: 0.007354836798266422  
 Epoch 10, Loss: 0.00556388366557182




**Figure 5:** Porównanie rzeczywistych i prognozowanych wartości dla PV3\_Zach

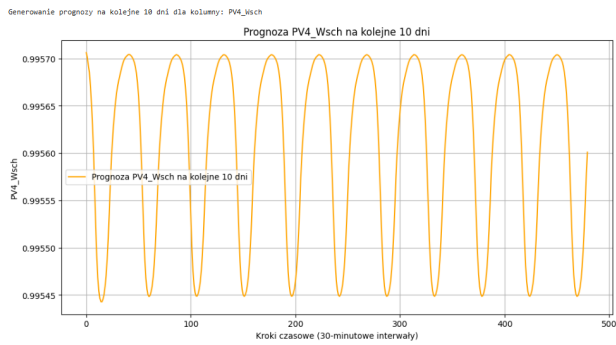
Generowanie prognozy na kolejne 10 dni dla kolumny: PV3\_Zach



**Figure 6:** Prognoza generacji energii na kolejne 10 dni dla PV3\_Zach



**Figure 7:** Porównanie rzeciwistych i prognozowanych wartości dla PV4\_Wsch



**Figure 8:** Prognoza generacji energii na kolejne 10 dni dla PV4\_Wsch